Reporte - Q-learning en Cliff Walking

Valeria Adriany Ix Villegas

Semilla: 42 Alpha: 0.5 Gamma: 1.0 Epsilon: 0.1 Episodios: 500

¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

Porque es el camino más corto posible de S a G. Tiene que subir 1, avanzar 11 a la derecha y bajar 1, en total 13 pasos. Como cada paso cuesta -1 y el acantilado cuesta -100, cualquier otro camino es más largo o se cae. Por eso 13 x (-1) = -13 es el mejor retorno posible, no se puede sacar más que eso.

¿Por qué la curva de entrenamiento queda por debajo de −13 aunque la política greedy ya sea óptima?

Porque la gráfica es de entrenamiento, no de evaluación. Durante el entrenamiento se sigue usando ϵ=0.1, o sea que en el 10% de los pasos el agente hace una acción al azar para explorar. Eso hace que a veces se caiga y saque -100 o más, aunque su política ya sea buena. Por eso la recompensa cruda tiene picos para abajo y la media móvil queda un poco por debajo de -13. El -13 solo sale cuando se evalúa la política greedy con ϵ=0.

En el paso que cae al acantilado, ¿cuál es s' en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

Cuando el agente pisa el acantilado, la recompensa es -100 y s' es S, el estado inicial. No es un estado terminal, porque el episodio no se acaba, solo lo regresan al inicio y sigue jugando. Por eso el backup de Q-learning es $r + \gamma \max Q(S, \cdot)$, con r = -100 y $s' = S$. Si fuera terminal, el backup sería solo r, pero aquí no es el caso.